

CONSTRUCCIÓN DE PROTOTIPO CLASIFICADOR DE TUBÉRCULOS DE PAPA MEDIANTE SUPERVISIÓN DE VISIÓN COMPUTACIONAL



**UNIVERSIDAD DE
SAN BUENAVENTURA**

**Jaither Bejarano Casas
John Jairo Caicedo Ferrer
Sergio Arley Rivera Jerez**

Universidad de San Buenaventura sede Bogotá
Facultad de Ingeniería
Programa de Ingeniería Mecatrónica
Bogotá D.C., Colombia
2022

Contenido

1	Introducción	3
1.1	Objetivos	4
1.1.1	Objetivo General	4
1.1.2	Objetivos Específicos	4
1.2	Alcances y Limitaciones	4
1.2.1	Alcances	4
1.2.2	Limitaciones	4
1.3	Justificación	5
1.4	Descripción y formulación del problema	5
2	Estado del arte	7
2.1	MatLab.	7
2.2	Artificial Neural Networks.	7
2.3	Super Vector Machine.	8
2.4	Otros métodos	9
3	Marco Conceptual	11
3.1	Agricultura de precisión	11
3.2	Artificial Neural Networks	11
3.3	Imagen Binaria	11
3.4	ISO 800	12
3.5	Procesamiento de imagenes	12
3.6	Reconstrucción morfológica	12
3.7	Tubérculos de papa	13
3.8	Visión artificial	13
4	Diseño Del Algoritmo de Clasificación	14
4.1	Preparación y Adquisición De Las Imágenes	15
4.2	Distribución del Dataset	17

5	Algoritmo de Clasificación	18
5.1	Red Neuronal Artificial Convolutacional	18
5.1.1	Preparación Del <i>Dataset</i>	19
5.1.2	Funciones PotatoDataset y DataLoader	23
5.1.3	Hiperparámetros Del Modelo	25
5.1.4	Optimización Bayesiana	26
5.1.5	Arquitectura del modelo	26
5.2	Clasificación de tamaño	29
6	Prototipo	30
	Bibliografía	31

1 Introducción

La agricultura ha sido uno de los pilares más importantes tanto para el desarrollo de la sociedad como para su manutención, ya que es gracias a esta, que los países pueden generar empleos y aumentar sus recursos económicos, sin embargo las tareas de agricultura pueden llegar a ser tediosas o muy pesadas para las personas, es por esto que con el avance tecnológico se ha buscado mejorar el sector de la agricultura no solo para facilitar a los agricultores las tareas que deben hacer, sino también permitir que el producto que se está ofreciendo sea de mayor calidad, para garantizar que su comercialización tenga un mayor auge globalmente.

Uno de los principales avances tecnológicos en el sector agroindustrial, es la implementación de la visión artificial en los procesos productivos, con esta se busca corregir las fallas humanas y garantizar que el producto mantenga siempre una buena y mejor calidad que busquen garantizar la normativa INCONTEC que se debe tener para la exportación de productos agrícolas. El proyecto busca desarrollar un sistema mecatrónico implementando técnicas de visión artificial para agilizar o mejorar el proceso de producción de la papa. El proyecto podría ayudar al crecimiento del sector papicultor del país debido a que se espera que la calidad del producto mejore y sea más eficiente su clasificación.

1.1. Objetivos

1.1.1. Objetivo General

Implementar un prototipo para la clasificación de características de calidad en los tubérculos de papa producidos en la región Andina de Colombia, mediante técnicas de visión por computadora.

1.1.2. Objetivos Específicos

1. Identificar a través de técnicas de visión artificial los rasgos de calidad y características físicas que se encuentran en los tubérculos de papa.
2. Evaluar el desempeño del prototipo propuesto para realizar la clasificación de los tubérculos de papa bajo las categorías de tamaño grande mediana y pequeña establecidas por la norma NTC341.
3. Comparar la precisión del modelo propuesto con modelos similares de clasificación

1.2. Alcances y Limitaciones

1.2.1. Alcances

Para la realización del proyecto se debe tener en cuenta que se enfocará en los tubérculos de papa R12 y pastusa producidos en la región andina de Colombia. Se espera que el producto se encuentre limpio de suciedades como tierra y raíces para llevar a cabo el análisis por técnicas de visión artificial. El análisis estará enfocado en identificar las características de calidad del producto para ser comercializado. Se propone un sistema mecatrónico tipo banda transportadora para generar el desplazamiento de los tubérculos de papa por debajo de una cámara que realiza el análisis de visión artificial que extrae las características de calidad de la papa.

1.2.2. Limitaciones

El proyecto se encuentra limitado a los recursos de software y hardware (computacionales) con los que cuentan los integrantes del proyecto y las plataformas open sources a las que se le puedan sacar provecho, para la implementación de los algoritmos que actualmente se encuentran en la literatura.

1.3. Justificación

EN el proyecto se desarrollará un sistema mecatrónico implementando técnicas de visión artificial para agilizar o mejorar el proceso de producción de la papa, con el fin de mejorar el proceso actual que se lleva a cabo para la clasificación de calidad en los tubérculos de papa. El cultivo de la papa constituye el eje fundamental de la economía del país en 283 municipios a nivel nacional, donde se involucran más de 90.000 familias principalmente en los departamentos de Boyacá, Cundinamarca, Antioquia y Nariño, los cuales concentran más del 85 % de la producción [1]. Actualmente, el reto que enfrenta el sector es el aumento de la calidad del producto, el rendimiento en producción y en consecuencia, incrementar el consumo. Debido a que la producción de papa en Colombia aporta el 3.3 % del Producto Interno Bruto (PIB) agropecuario, las siembras son de alrededor de 130 mil hectáreas y se cosechan cerca de 2,8 millones de toneladas. Además, en Colombia la producción de papa genera anualmente alrededor de 264.000 empleos, aproximadamente 75.000 son trabajos directos y alrededor de 189.000 son indirectos [2]. Así, el presente trabajo permitirá mostrar los beneficios que trae la implementación de técnicas de visión artificial que podrían generar un crecimiento al sector papicultor del país para competir con el mercado internacional.

1.4. Descripción y formulación del problema

La agricultura de Colombia es un componente fundamental en la economía del territorio que juega un papel primordial en el desarrollo económico del país. Debido a que es la principal fuente de ingresos del área rural, hace un aporte relevante al desarrollo económico, la mitigación de la pobreza, y el desarrollo sustentable de Colombia. Uno de los sectores más grandes en la agricultura colombiana es el sector papicultor, en Colombia se caracteriza por tener poco desarrollo tecnológico y buscar abastecer el consumo interno, sin mayor exploración en mercados internacionales. Frente a la coyuntura en la que se encuentra el sector gracias a los retos que trae consigo los acuerdos comerciales firmados por el gobierno nacional, el sector papicultor requiere urgentes transformaciones que permitan aumentar su competitividad y por ende lograr el crecimiento del sector. Como consecuencia en los últimos años el sector agricultor de Colombia ha implementado herramientas tecnológicas que le permitan a los agricultores aumentar la calidad de sus productos y así poder competir tanto en el mercado local como en el global. Pensando en esto las diferentes técnicas de visión artificial han tenido un auge en la agricultura de precisión ayudando a clasificar productos basándose en sus diferentes características sin importar su clase, sin embargo, las técnicas de visión artificial no han sido aprovechadas para mejorar el sector papicultor colombiano. El sector agricultor de Colombia ha implementado

diferentes técnicas de visión artificial las cuales ayudan a clasificar los productos mediante las características que estos poseen, sin embargo no se ha implementado estas técnicas en la fase de almacenamiento de los tubérculos de papa, la cual es importante ya que en esta fase es donde se separan los tubérculos que cumplen las condiciones de calidad de los tubérculos que se encuentran defectuosos, ya que para la comercialización de este producto deben estar clasificados según la norma NTC 341.

¿Cómo se puede aumentar la eficiencia al clasificar los tubérculos de papa bajo la norma NTC341 mediante técnicas de visión artificial para su distribución comercial?

¿Qué tipo de proceso de clasificación permitirá agrupar los tubérculos de papa según sus características físicas y "patologías" mediante técnicas de visión artificial?

2 Estado del arte

El objetivo de los antecedentes es analizar y realizar una revisión literaria sobre lo que se ha hecho a nivel teórico y práctico en cuanto a la visión artificial en agricultura de precisión. Además, determinar cuáles son los aportes que éstos le puedan dar a este trabajo de investigación.

2.1. MatLab.

Comenzando por la literatura con temática en el procesamiento de imágenes, se tiene el trabajo de textitJ. porras, M. De La Cruz y A. Morian [3], en donde se menciona que la implementación de MATLAB[®] como una herramienta de procesamiento de imágenes, radica en su facilidad para realizar cambios a las imágenes, es por esto que diseñó un sistema para la clasificación de objetos en base a su forma y color usando métodos de visión artificial en MATLAB[®] con el uso de la librería *ufm.dll* para capturar y procesar imágenes. El artículo de C. Nandi [4] presenta una investigación en donde se consiguió calcular el tamaño de diferentes mangos, estimando el área cubierta en una imagen binaria (imagen digital que tiene únicamente dos valores posibles para cada píxel) con base al número de píxeles, luego de ser procesadas las imágenes, se clasificaron implementando un algoritmo basado en *fuzzy logic*, teniendo en cuenta 5 variedades diferentes de mangos y como referencias el color de la cascara, tamaño, defectos superficiales, forma, firmeza, peso y olor.

2.2. Artificial Neural Networks.

En cuanto a la clasificación, se deben usar técnicas de visión artificial y en primer lugar, se revisó literatura acerca de ANN (*Artificial Neural Networks*) como el trabajo de L. Pencue-Fierro y J. León Téllez [5], en donde se aborda una investigación hecha en Perú en donde se aplicó visión artificial usando ANN como método de clasificación de las principales características extraídas de las frutas, que son derivadas del análisis de las superficies tanto en su contenido cromático como en la cantidad y distribución de defectos

externos. De igual forma, en el trabajo publicado en la revista *Multimedia Tools and Applications* [6], donde presentaron un sistema de visión artificial que usa un enfoque de categorización simplificado con un elevado índice de exactitud. El propósito del sistema es clasificar los granos de trigo de las especies *triticum aestivum* y *triticum durum* según sus propiedades visuales usando una ANN del tipo MLP (*Multilayer Perceptron*); las imágenes se obtienen por medio de una cámara que captura las propiedades de tamaño, color y textura de cada grano con el objeto de que sirvan de acceso al procedimiento de categorización. Otro trabajo es el publicado por *Ksh. Robert Singh y Saurabh Chaudhury* [7], en donde se propone el uso de redes neuronales BPNN (*Back Propagation Artificial Neural Networks*) como método de clasificación y la descomposición mediante ondículas (Tipo especial de transformada matemática que representa una señal en términos de versiones trasladadas y dilatadas de una onda finita) para clasificar los granos de arroz. El modelo de clasificación implementó una red neuronal BPNN de cuatro capas la cual presentó mejores resultados en comparación con otros métodos.

Por último, usando el método de clasificación ANN, se tiene el trabajo hecho por *Krzysztof Przybyl, Piotr Boniecki, Krzysztof Koszela, Lukasz Gierz y Mateusz Lukomski* [8], donde se presenta se investiga una forma para garantizar la correcta clasificación de los productos y reducir las pérdidas durante su almacenamiento. La investigación abarca esfuerzos centrados en la evaluación sensorial de patatas con el análisis de imágenes por ordenador y la modelización neuronal ANN. El objetivo de este estudio fue desarrollar un método para asistir a la identificación de cualquiera de las variedades y la turgencia de los tubérculos de patata (Fenómeno que ocurre cuando una célula se dilata debido a la presión ejercida por los fluidos y por el contenido celular sobre las paredes de la célula) llevado a cabo sobre la base de los datos gráficos codificados en forma de imágenes digitales, obtenidos mediante algoritmos que interpretan los descriptores de imagen.

2.3. Super Vector Machine.

Otro método de clasificación revisado en la literatura es el de SVM (*Super Vector Machine*), como el usado en el trabajo de *Tao Liu* y otros investigadores [9], en donde realizaron un proceso para analizar granos de arroz. El procedimiento usa 4 fuentes de luz para crear la sombra del grano en 4 direcciones; la diferencia en medio de las siluetas de los granos llenos y no llenos se evalúan por medio del estudio de imágenes y un clasificador SVM. El análisis se hace mediante el uso de imágenes RGB (Red-Green-Blue) de los granos con las siluetas, luego se segmentan desde la imagen binaria, para sustraer información como el sector del grano y de la sombra. En el documento *Chia-Lin* y otros investiga-

doores [10], se menciona un método para clasificar plántulas (Embrión ya desarrollado como consecuencia de la germinación de una semilla) sanas e infectadas. Consiste en el análisis de imágenes mediante un escáner y el proceso de clasificación utilizando SVM, en donde se hace uso de dos clasificadores, el primero distingue entre las plantas sanas y contaminadas, por otra parte, el segundo mide los niveles de contaminación. En el trabajo de *Rillian Diello y Lucas Pires* [11], se propuso un método de detección automática de enfermedad en cultivos de soja, el cual se basa en descripciones locales conocido como el método BOV (Bag of Values) luego de escanear la hoja. Se obtuvo a través de los vectores de entrada una clasificación en dos categorías, enfermo y sano, a partir de un clasificador SVM. Y por último, en este tipo de clasificador, el trabajo de *Chengming Sun y Tao Liu* [12], se propone un sistema para analizar el porcentaje de granos en el arroz que se encuentran en condiciones para ser distribuidos. El algoritmo se encarga de la división de los granos de manera automática. Tras la segmentación, es viable obtener el número de granos presentes en la imagen y la información específica, la exactitud del procedimiento puede verse afectada si el germen no se extrae del todo, por esa razón el sistema detecta la viable región de germen y estima esta información usando SVM.

2.4. Otros métodos

En la literatura se encontraron artículos que usaban más de un método de clasificación, un ejemplo es el trabajo hecho por *Tao Liu y Wen Chen* [13] que puso en práctica un método para controlar la población de pulgones (Familia de insectos hemípteros) en el trigo, usando los métodos SVM, el algoritmo MSER (*Maximally Stable Extremal Regions*), y el HOG (*Histogram of Gradients*). El uso de estos 3 métodos se conoce como SMH (Unión entre SVM, MSER y HOG), que se basa en el análisis de imágenes, tratadas a partir de unos parámetros con la finalidad de detectar la presencia y/o ausencia de pulgones, se hizo uso de este método a partir del color y la densidad de población. Al comparar este método con otros cinco comúnmente utilizados, los resultados presentaron un rendimiento superior en la identificación de pulgones.

De igual manera, el artículo de *Rodica Sobolu* [14] propone un algoritmo de clasificación automática de patatas. Se realizaron dos tipos de clasificación: una en función del tamaño de las patatas y otra en función de su calidad. La segmentación de las zonas defectuosas se hizo mediante métodos como *global thresholding* para extraer características morfológicas y estadísticas de las zonas segmentadas. Estas características se eligieron como entradas para los algoritmos de clasificación, en donde se usaron los métodos SVM, *Decision Tree* y LDA (*Linear Discriminant Analysis*) implementados en MATLAB® Classification Tool-

box. Se llegó a la conclusión de que la SVM ha clasificado las patatas según su tamaño con una mayor tasa de éxito. En el caso de la clasificación por calidad, se recomienda el método LDA.

Los anteriores son los métodos más comunes que se encontraron en la literatura investigada, sin embargo, hay unos métodos poco comunes como por ejemplo los presentados en el artículo de *Alberto Martines Rodriguez* [15] en donde se identificaron objetos en movimiento mediante la ayuda de la visión artificial y la transmisión de datos a un brazo robótico implementando *C++* y *Open CV*, usando el código de cadena (Actualmente el grupo de reconocimiento de patrones e inteligencia artificial aplicada) para calcular las características de los objetos por color y forma. También, el artículo hecho por *L. Han y M. S. Haleem* [16] que se usa para la detección automática, fue necesario hacer uso inicialmente de separar el fondo de la hoja, para este proceso se usó el algoritmo MCW (*Marker-Controlled Watershed*). El SLIC (*Simple Linear Iterative Clustering*) se utilizó para obtener las características presentadas por la enfermedad sobre la planta y por último, la clasificación y textura se obtienen a través de GLCM (*Gray Level Co-occurrence Matrix*), el modelo de clasificación fue el SVM, este método propuesto presentó un mayor rendimiento.

El último artículo revisado es presentado por *Michael Barnes y Tom Duckett* el [17], cuyo objetivo de investigación es introducir un método automático de detección de manchas en imágenes digitales de patatas. El sistema desarrollado es entrenable, de modo que pueda trabajar con diferentes variedades de patatas y variaciones en las estaciones, condiciones de iluminación, etc. Otro objetivo, pensando en su posible implantación en entornos industriales, es permitir el procesamiento de imágenes en tiempo real, posiblemente mediante la construcción de *Minimalist Boosted Classifier* que extraigan un subconjunto mínimo de todas las características que optimicen el rendimiento de la detección con el menor coste computacional posible.

3 Marco Conceptual

3.1. Agricultura de precisión

El término sobre el que se inspira la agricultura de precisión es utilizar la porción adecuada de insumos, en el instante correcto y en el sitio preciso. La agricultura de precisión (AP) implica la utilización de sistemas de posicionamiento universal (GPS) y de otros medios electrónicos para obtener datos del cultivo. Las tecnologías de la agricultura de precisión permiten saciar una de las exigencias de la agricultura actualizada: el funcionamiento óptimo de enormes extensiones. Se muestra como primordial virtud que la exploración de resultados de los ensayos se puede hacer por sectores diferentes en un mismo lote, y tal cual ajustar el desempeño diferencial en los mismos. La utilización de las tecnologías de la agricultura de precisión puede contribuir a mejorar los márgenes, por medio de un incremento del costo del rendimiento (cantidad o calidad), de una reducción en la proporción de insumos, o de los dos paralelamente.

3.2. Artificial Neural Networks

Las RNA son sistemas de procesamiento de la información cuya composición y manejo permanecen inspirados en las redes neuronales biológicas. Consisten en un enorme conjunto de recursos básicas de procesamiento denominados nodos o neuronas que permanecen organizados en capas. De esta forma, las RNA son sistemas adaptativos que aprenden de la vivencia, en otros términos, aprenden a realizar ciertas labores por medio de un entrenamiento con ejemplos ilustrativos.

3.3. Imagen Binaria

La binarización de una imagen se apoya en un proceso de reducción de la información de la misma, en la que únicamente persisten 2 valores: verdadero y falso. En el proceso y estudio de imagen, la binarización se emplea para dividir las zonas u objetos de interés en

una imagen del resto. En otras ocasiones, una imagen binaria es sencillamente el resultado de una selección interactiva de zonas de interés, las cuales se usarán como máscaras de comparación o alusión.

3.4. ISO 800

ISO no es más que la sensibilidad del sensor en el momento de captar la luz. A más grande número de ISO, más grande capacidad para captar luz, a menor costo, menor capacidad para capturar esa luz. Una vez que duplicas el costo ISO, o sea, pasas de, ejemplificando, ISO 100 a ISO 200, necesitas la mitad de luz para poder hacer la misma exposición.

3.5. Procesamiento de imágenes

El procesamiento de imágenes tiene como fin mejorar el aspecto de las imágenes y hacer más evidentes en ellas ciertos detalles que se quieren hacer percibir. La imagen puede haber sido generada de muchas posibilidades, ejemplificando, fotográficamente, o electrónicamente, mediante monitores de televisión. El procesamiento de las imágenes se puede generalmente hacer mediante procedimientos ópticos, o bien mediante procedimientos digitales, en una PC. En la siguiente parte describiremos bastante brevemente dichos 2 procedimientos, sin embargo, previamente se va a hacer una síntesis brevísima de los principios matemáticos implícitos en los dos procedimientos, donde el teorema de Fourier es el eje central.

3.6. Reconstrucción morfológica

La recomposición morfológica se puede tener en cuenta conceptualmente como dilataciones reiteradas de una imagen, denominadas, hasta que el contorno de la imagen del marcador se adapta bajo una segunda imagen, llamada imagen de máscara. En la recomposición morfológica, los picos de la imagen del marcador "se alargan." se dilatan.

3.7. Tubérculos de papa

La papa o patata es un tubérculo que se puede comer que se extrae de la planta herbácea americana *Solanum tuberosum*, de procedencia andino. Es una planta correspondiente a el núcleo familiar de las solanáceas procedente de Suramérica y cultivada por todo el planeta por sus tubérculos víveres. Ha sido domesticada en el altiplano andino por sus pobladores entre el 8500 y el 5000 a. n. e., y después ha sido llevada a Europa por los colonizadores españoles como una curiosidad botánica más que como una planta alimenticia. Su consumo ha sido creciendo y su cultivo se expandió a todo el planeta hasta transformarse actualmente en uno de los más importantes alimentos para la gente.

3.8. Visión artificial

La perspectiva artificial ayuda a la industria a mejorar los procesos de producción por medio de imágenes digitales, con ellas se optimiza el control de calidad de aplicaciones industriales y de robots. Los sistemas de perspectiva examinan y se aseguran de conseguir los requisitos mínimos de calidad exigidos por cada fabricante. A lo largo del proceso de inspección los sistemas de perspectiva informan de los probables errores detectados, lo cual posibilita un mejor control del proceso de producción.

4 Diseño Del Algoritmo de Clasificación

Se diseñó un algoritmo de clasificación utilizando Redes Neuronales Convolucionales y técnicas de visión artificial con la librería *Open CV* para clasificar las características de tipo, daño y tamaño de tubérculos de papa. El Procedimiento que se llevó a cabo se presenta en la 4-1, cada ítem será explicado en las siguientes secciones.



Figura 4-1: Arquitectura del Sistema de Clasificación

El sistema propuesto para realizar la clasificación de tubérculos de papa en este documento, consiste desde la adquisición de muestras y creación de un dataset de tubérculos de papa hasta el diseño de un algoritmo de clasificación con Redes Neuronales utilizando la librería *Pytorch* y la librería *Open CV* de *Python*. Será implementado en un prototipo de banda transportadora que permita el movimiento de los tubérculos de papa para ser clasificados mediante un microcontrolador y una cámara. Los sistemas de Visión Artificial que se destinan a realizar inspecciones visuales permiten que el proceso sea más eficiente si requieren alta velocidad, gran aumento en cantidad de producción y en funcionamiento las 24 horas del día o la repetibilidad de las medidas [18].

4.1. Preparación y Adquisición De Las Imágenes

Se preparó un total de 592 tubérculos de papá que manualmente fueron clasificados en tres categorías definidas. Las etiquetas de cada imagen se encuentran dentro del nombre de cada archivo, que corresponde al metadata de cada foto tomada. Definido de la siguiente manera:

- *Tipo*: Pastusa o R12 [0, 1]
- *Daño*: Buena y Defectuosa [0, 1]
- *Tamaño*: Muy grande, Grande y Mediana [0, 1, 2]
- *Numero de la Imagen* Etiqueta asignada por la cámara.

Las fotos tomadas para la creación del *Dataset* poseen un tamaño de (3168, 4752) píxeles. Fueron tomadas con una cámara profesional *Canon EOS 50D* que tiene 15.1 mega píxeles de resolución y se puede ajustar la sensibilidad ISO desde 100 a 3200. La cámara fue configurada con ISO-800 que corresponde al parámetro de sensibilidad del sensor de ruido de la cámara, una velocidad de obturación de $\frac{1}{640}$ segundos que corresponde al dispositivo que controla el tiempo en el que la luz incide sobre el sensor de la cámara y finalmente una apertura de diafragma de $F7,1$ que corresponde a la apertura del lente que deja pasar la luz [19], tener en cuenta que a mayor apertura de diafragma, menor luz se deja pasar. Se construyó una caja con iluminación fija **4-2** usando bombillos de luz blanca de 6500 Kelvin de temperatura de color para que la iluminación en todas las fotos tomadas fuera uniforme y la cámara fue fijada a un trípode a 30 *cm* de la base para que la distancia del lente de la cámara a la muestra de papa fueran siempre la misma en las 592 fotos.



Figura 4-2: Récamara Para la Toma de Fotos

Utilizando la librería *Pandas* de *Python*, se creó un *Dataframe* que contiene el metadata de cada imagen. En la tabla **4-1** podemos apreciar la distribución del *MetaData* de las imagenes almacenadas en el *Dataset*, donde se toman cinco imágenes al azar como muestra. A partir de esta tabla se crea un archivo *.CSV* donde se encuentra la informacion de las 592 imagenes.

Tipo	Daño	Tamaño	Filename
R12	Defectuosa	Grande	1_1_1_075.JPG
PASTUSA	Buena	Grande	0_0_1_1973.JPG
R12	Buena	Grande	1_0_1_2054.JPG
PASTUSA	Buena	Mediana	0_0_2_2042.JPG
PASTUSA	Buena	Grande	0_0_1_1955.JPG

Tabla 4-1: MetaData de 5 Imágenes de Muestra

Una vez la información de cada imagen fue guardada en el archivo *metadata.csv*, se agruparon las posibles combinaciones de las características de *Tipo* y *Daño* para definir las *clases* dentro de la red neruonal. Para realizar este proceso se creó una condición dentro del *Dataframe* que contiene el *Metadata* para generar una columna adicional con la información de la tabla **4-2**.

PASTUSA	R12	Buena	Defectuosa	Clase
X		X		CLASE 1
X			X	CLASE 2
	X	X		CLASE 3
	X		X	CLASE 4

Tabla 4-2: Clases Definidas

De esta forma se definieron las 4 *clases* que serán entrenadas en la red neuronal para el posterior proceso de clasificación por visión artificial.

4.2. Distribución del Dataset

Para determinar la distribución total del dataset, con el uso de la librería *Plotly* se crearon gráficas para determinar el porcentaje de imágenes pertenecientes cada característica definida en el *Dataset*. La figura 4-3



Figura 4-3: Distribución del Dataset Según Sus Características Y Clases Definidas

Se definieron los *Set's* de *Train* y *Test*, que fueron creados para el entrenamiento y validación de la red neuronal a partir del archivo *metadata.csv* de la tabla 4-1. Se utilizó 80 % para *Train* y 20 % para *Test*. Se crearon los archivos *train.csv* y *test.csv* que contienen el *metadata* y la dirección de las imágenes separadas en el respectivo 80 % y 20 %.

5 Algoritmo de Clasificación

5.1. Red Neuronal Artificial Convolucional

Se desarrolló una red neuronal artificial (*CNN*) para clasificar las características de tipo y daño de los tubérculos de papas descritos en el *Metadata 4-1*. La arquitectura general de una red artificial convolucional (*CNN*) se muestra en la figura 5-1 [20]. Se realizaron pruebas con las arquitecturas *Alexnet*, *Resnet18*, *VGG11* y *VGG19* y se implementó la optimización bayesiana en ciertos hiperparámetros de las arquitecturas existentes para mejorar los resultados.




Figura 5-1: Arquitectura General De Una CNN

El procedimiento realizado para desarrollar la red neuronal, descrito en la figura 5-2, indica los pasos a seguir previo a implementar alguna de las arquitecturas. Cada item será descrito en las próximas secciones.




Figura 5-2: Procedimiento Diseñado Para Implementar La *CNN*

5.1.1. Preparación Del Dataset

DATA AUGMENTATION

El Data augmentation consiste en la transformación de los datos existentes para crear un *dataset* con mayor cantidad de datos diferentes. El objetivo de esta herramienta es crear nuevos datos que puedan ser añadidos al conjunto ya existente y así contar con más muestras para un mejor desempeño del algoritmo. Además de esto también es implementado para reducir el *overfitting* ya que al añadir más información al conjunto de entrenamiento se evita que el modelo se sobreajuste.

El concepto Data Augmentation tiene relación con los procedimientos para edificar algoritmos iterativos de mejora o muestreo por medio de la introducción de datos no vigilados o cambiantes latentes. Para los algoritmos estocásticos, el procedimiento se popularizó en la literatura estadística por el algoritmo de incremento de datos de Tanner y Wong y en la literatura de física por el algoritmo de Swendsen y Wang para el muestreo de los modelos de Ising y Potts y sus generalizaciones; en la literatura de física, el Data Augmentation se conoce como el procedimiento de las cambiantes auxiliares. Generalmente, no obstante, la obra de esquemas de el Data augmentation es que den sitio a algoritmos básicos y rápidos, debido a que las tácticas famosas varían de una manera significativa con respecto a los modelos.[21]

PREPROCESAMIENTO DE IMÁGENES

Usando el módulo *torchvision.transforms.compose()* de la librería *Pytorch* se puede encadenar unas determinadas funciones que aplican diferentes tipos de filtros y transformaciones al *Dataset*. De esta forma se puede crear la tarea de segmentación debido a que las transformaciones aumentan en consideración el tamaño original del *Dataset*, facilitando así, la extracción de características de cada imagen [22]. Las transformaciones disponibles en éste módulo se presentan a continuación:

Image Transform	Use	Image Transform	Use
CenterCrop	Recorta la imagen en el centro	RandomResizedCrop	Recorta una porción aleatoria de la imagen y la redimensiona a un tamaño determinado
ColorJitter	Cambia aleatoriamente el brillo, el contraste, la saturación y el tono de una imagen	RandomRotation	Rota la imagen a un ángulo determinado
FiverCrop	Recorta la imagen en cuatro esquinas y el recorte central	RandomVerticalFlip	Voltea verticalmente la imagen al azar con una probabilidad dada
Grayscale	Convierte la imagen en escala de grises	Resize	Redimensiona la imagen al tamaño dado
Pad	Rellena la imagen en todos sus lados con el valor de "pad" dado	TenCrop	Recorta la imagen dada en cuatro esquinas y el recorte central más la versión volteada de éstas
RandomAffine	Transformación afín aleatoria de la imagen manteniendo el centro invariante	GaussianBlur	Desenfoca la imagen con un filtro gaussiano

Tabla 5-1: Funciones de transformación de imágenes del módulo de *Pytorch*

En la tabla **5-1** se observa una parte de las transformaciones de imágenes disponibles en el módulo *torchvision.transforms.compose* de la librería *Pytorch*. En el caso del *Dataset* de papas creado, se deben tener en cuenta únicamente las transformaciones cuyo resultado

sea relevante para la extracción de características de la imagen, por ejemplo, como se explicó anteriormente, se va a clasificar el tubérculo de papá en tipo y daño con la red neuronal, por este motivo, el color es una característica que define si la papa pertenece a la clase *R12* o *Pastusa* y, en algunos casos, si se encuentra con algún tipo de daño, por este motivo, los filtros que transforman la imagen en escala de grises no son relevantes y podrían afectar el rendimiento del algoritmo.

Image Transform	Use	Image Transform	Use
Randomcrop	Recorta la imagen aleatoriamente	RandomInvert	Invierte los colores de la imagen de forma aleatoria
RandomGrayscale	Convierte la imagen en escala de grises aleatoriamente	RandomPosterize	Reduce el número de bits de cada canal de la imagen de forma aleatoria
RandomHorizontalFlip	Voltea horizontalmente la imagen al azar con una probabilidad dada	RandomSolarize	Invierte aleatoriamente el valor de los píxeles por encima de un umbral
RandomPerspective	Realiza una transformación de perspectiva aleatoria de la imagen	RandomAutocontrast	Autocontraste de los píxeles de la imagen dada aleatoriamente
RandomAdjustSharpness	Ajusta la nitidez de la imagen de forma aleatoria	RandomEqualize	Equaliza el histograma de la imagen dada aleatoriamente
RandomApply	Aplicar aleatoriamente una lista de transformaciones con una probabilidad determinada.		

Tabla 5-2: Funciones de transformación de imágenes del módulo de *Pytorch*

De igual forma, en la tabla 5.1.1, se observan algunos filtros como recortes en la imagen, rotaciones, cambios de perspectiva, cambios en la nitidez y contraste de la imagen. Se escogieron los filtros considerados mejores para el caso del *Dataset* de tubérculos de papa creado en este documento.

Los filtros que se utilizaron en el desarrollo del algoritmo de clasificación, teniendo en cuenta aquellas transformaciones que podrían afectar el rendimiento del algoritmo fueron:

- Resize
- ColorJitter
- RandomRotation
- GaussianBlur
- RandomPerspective
- RandomAdjustSharpness

Como se está utilizando la librería *Pytorch*, las imágenes deben ingresar en formato *Tensor*, que convierte los valores de los píxeles de una imagen *PIL* estándar con un rango de $[0, 255]$ a un tensor decimal de *Pythorch* con valores en un rango de con valores $[0, 0, 1, 0]$ de la forma (C, H, W) , siendo C el número de canales de la imagen (1 si es en escala de grises, 3 si es *RGB*), H y W el tamaño de la imagen.

Una vez la imagen está en formato *PyTorch FloatTensor*, se decidió utilizar la función *torchvision.transforms.normalize()* para normalizar las imágenes. La normalización de una imagen consiste en modificar los valores del tensor, que se encuentran entre $[0, 0, 1, 0]$ para que el promedio y la desviación estándar sean 0 y 1 respectivamente. Para hacer esto se utiliza la ecuación 5-1 [22]

$$output[Channel] = \frac{Input[Channel] - Mean[Channel]}{std[Channel]} \quad (5-1)$$

La normalización se utiliza debido a que ayuda a los datos a estar definidos dentro de un rango y reducir la asimetría entre ellos, lo que permite un aprendizaje más rápido. Se diseñó una función en *Python* que calcula el promedio y la desviación estándar para *Trainset* y para el *Testset*. De esta forma se garantiza que la normalización sea correcta en el total del *Dataset*. Los valores obtenidos para el *Trainset* 5-2 y el *Testset* 5-3 respectivamente.

$$mean = [0,7467, 0,7389, 0,7432] \quad std = [0,1288, 0,1633, 0,2045] \quad (5-2)$$

$$mean = [0,7507, 0,7430, 0,7486] \quad std = [0,1265, 0,1609, 0,2012] \quad (5-3)$$

La figura 5-3 enseña una matriz de imágenes como parte del *Trainset*, que muestra las transformaciones hechas al 80 % de las imágenes del *Dataset* y la clase a la que pertenece 4-2, verificando así que las funciones creadas están enlazando correcta la imagen con su respectiva clase y aplicando de forma correcta las transformaciones.

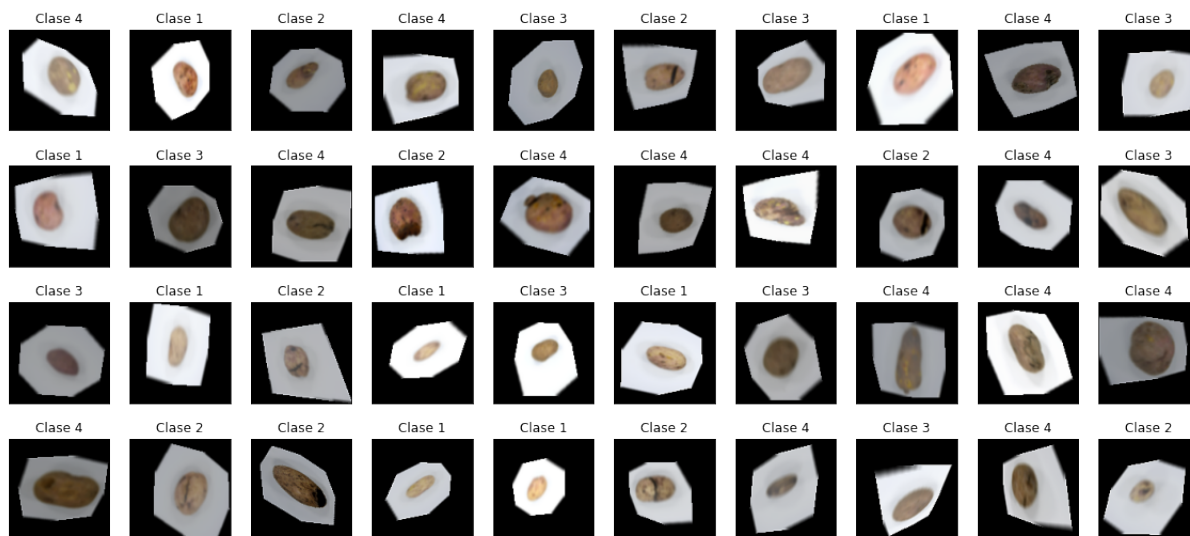


Figura 5-3: Matriz de Imágenes Con Transformaciones Aplicadas

5.1.2. Funciones PotatoDataset y DataLoader

FUNCIÓN POTATODATASET

Se creó una clase (*Python Class Object Constructor*) con el nombre de *AttributesDataset()* que se encarga de leer el *Metadata* de cada imagen y convertirlo en *labelID* en la tabla 4-1 se muestra como son ingresadas las imágenes en el algoritmo, sin embargo, las características deben ser ingresadas como *labelID*, es decir, el label Pastusa corresponde al ID 0 en la categoría de Tipo. Este diccionario se presenta a continuación:

- Tipo: 'Pastusa' : 0, 'R12' : 1
- Daño: 'Buena' : 0, 'Defectuosa' : 1
- Tamaño: 'MuyGrande' : 0, 'Grande' : 1, 'Mediana' : 2

En la red neuronal únicamente se utilizaron *labels* y *labelID* de tipo y daño para definir las clases 4-2. La función *Dataset* de *Python* realiza el proceso cargar y relacionar relacionar cada imagen con su respectivo *label* para *Dataset's* que se encuentran organizados dentro de carpetas jerárquicamente. El *Dataset* creado en éste documento no se encuentra organizado de esta manera, sino que la organización jerárquica que define las clases se encuentra dentro del *metadata* en el nombre de cada imagen 4-1, debido esto es que se desarrolló una función que cargara y relacionara de la misma manera que lo hace la función integrada de *Pythorch*. Esta función fue llamada *PotatoDataset()* que utiliza los

labelID generados por la función *AttributesDataset()* y carga cada imagen relacionada con sus *labelID*. Como se desarrolló la función, de igual forma debe ser capas de aplicar las transformaciones a cada imagen. El objeto regresa las 592 imágenes cargadas en *Python* cada una relacionada con su respectivo *labelID* y *label* y con una transformación o múltiples aplicadas. Esta función desarrollada cuenta con los mismos atributos iterables que poseen los *dataset's* creados a partir de la función integrada en *Pytorch*.

FUNCIÓN DATALOADER

Generalmente una vez se finaliza el proceso de cargar las imágenes utilizando la función *DataSet* de *Pytorch*, se procede a utilizar la función *DataLoader* para generar múltiples lotes de imágenes a partir de las transformaciones utilizadas. La función *DataLoader()* de *Pytorch* es implementada para realizar la importación de datos a gran escala. Para el uso de esta función se debe tener en cuenta que el argumento más importante será el *dataset* que fue generado por el objeto *PotatoDataset()*.

Según como se explico en el apartado anterior, se generó un *dataset* del tipo *iterable-style Datasets*, lo que permite utilizar la función integrada *DataLoader()* de *Pytorch*. El *DataLoader* permite la agrupación automática de muestras de datos individuales obtenidas en los *Batch's* mediante argumentos. Los *DataLoader's* cuentan con una gran catidad de argumentos que ayudan para que la carga de datos sea más eficiente [22]. Es por esta razón que para la ejecución de este dataloader se implementarán los siguientes parametros:

FUNCIÓN	DESCRIPCIÓN
Batch size	Cuántas muestras por Batch hay que cargar (Default: 1)
Shuffle	Se establece en TRUE para que los datos se reorganicen en cada época (Default: FALSE)
Num workers	Cuántos subprocessos se utilizarán para la carga de datos. 0 significa que los datos se cargarán en el proceso principal. (Default: 0)

Tabla 5-3: Argumentos para el Dataloader

Los argumentos explicados en la tabla anterior fueron establecidos de la siguiente forma:

- *Batch Size* = 40
- *Shuffle* = *True*
- *Num workers* = 0

Esto con el obojtivo de que el *Dataloader* cargue 40 muestras por época y tome otras 40 diferentes para la siguiente época y asi sucesivamete hasta terminar todas las epocas establecidas.

5.1.3. Hiperparámetros Del Modelo

FUNCIÓN DE PÉRDIDAS

Pytorch posee una cantidad interesante de funciones de pérdidas para su uso la clasificación de clases en redes neruonales. Una función de pérdidas evalúa la desviación entre las predicciones realizadas por la red neuronal y los valores reales de las muestras utilizadas durante el entrenamiento de la red. Cuanto menor sea el valor de la función, es más eficiente la red neuoral [23]. Para el desarrollo de nuestra red neuronal, se utilizó la pérdida de entropía cruzada entre la entrada y el objetivo o *Cross Entroppy Loss* [22]. Es útil cuando se entrena un problema de clasificación con más de una clase. El objetivo que espera este criterio debe contener:

- Índices de clase en el rango $[0, C)$ donde C es el número de clases.
- Probabilidades de clase se requieren más allá de una sola clase cuando se encuentran etiquetas combinadas.

En cada *Batch* usado en el entrenamiento de la red neuronal se encuentran etiquetas combinadas en el *Metadata* de las imágenes como se describió en la tabla 4-2, por lo tanto, una función de pérdida no reducida [22] descrita como:

$$l_n = - \sum_{c=1}^C w_c \log \left(\frac{\exp(x_n, c)}{\sum_{i=1}^C \exp(x_n, i)} y_n, c \right) \quad (5-4)$$

Donde x es la entrada, y el objetivo de predicción, w es el peso, C el número de clases y N es la dimensión del *Batch*. Usando la función *nn.CrossEntropyLoss()*, se calculan las pérdidas entre entrada y salida del modelo entrenado, para posteriormente utilizar estas pérdidas como métricas en porcentajes de *Accuracy* y *Losses*.

El rendimiento de esta función de pérdidas es mejor cuando el objetivo contiene índices de clase y no las etiquetas, ya que esto permite optimizar el cálculo, por esta razón, se agruparon las etiquetas de las imágenes en 4 *Clases* definidas.

OPTIMIZADOR

Pytorch posee *torch.optim* que es un paquete que implementa varios algoritmos de optimización.

5.1.4. Optimización Bayesiana

5.1.5. Arquitectura del modelo

MODELO PREENTRENADO ALEXNET

El modelo AlexNet fue implementado en el año 2012 en el desafío de reconocimiento visual a gran escala ImageNet. Este modelo tuvo un resultado tan satisfactorio que los modelos de aprendizaje profundo se convirtieron en la referencia para la investigación y desarrollo en los principales sectores de la industria. [22]

El modelo se compone de cinco capas convolucionales y tres capas densas, donde las capas convolucionales están normalizadas por lotes. El kernel tiene dimensiones diferentes que se distribuyen en 11x11 en la primera capa, 5x5 en la segunda y 3x3 en el resto. La primera, cuarta y quinta capa convolucional están seguidas por una capa Max-pooling con dimensiones de 3x3 que posee un stride de dos.

Las capas convolucionales y de Max-pooling son seguidas por tres capas densas en donde las dos primeras poseen 4096 neuronas cada una y la última capa es la de salida la cual se compone de 1000 neuronas que poseen una función de activación softmax. Estas neuronas son las encargadas de realizar la clasificación de la imagen. Como es habitual en estos sistemas de clasificación, la función de pérdidas implementada es la entropía cruzada. (REFERENCIA)

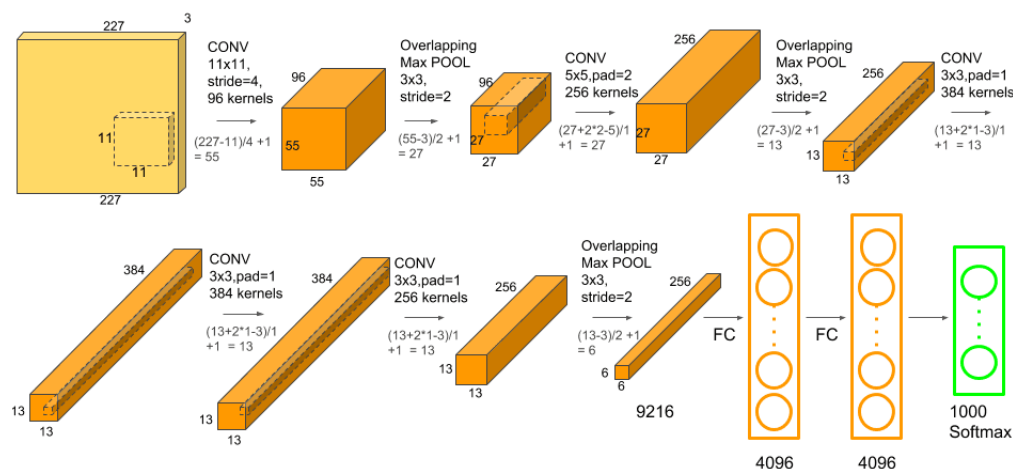


Figura 5-4: Modelo AlexNet

El modelo de AlexNet toma una imagen de entrada con una resolución de 227x227píxeles y 3 canales de color, la información recibida pasa por cinco capas convolucionales (en negro) de neuronas ReLu y tres capas de Max-pooling (en azul). La quinta capa de convolución posee 256 mapas diferentes con dimensiones de 13x13. Seguidamente se aplican las dos capas densas de 4096 neuronas las cuales son seguidas por una capa de salida de 1000 neuronas, dotadas con una función softmax. Cada neurona de la capa de salida representa un conjunto semántico diferente. Y su valor de activación indica la probabilidad de que la imagen de entrada pertenezca a dicho conjunto semántico.

Una vez conocida la estructura del modelo procedemos con la implementación, en la cual se siguieron una serie de pasos para la construcción del modelo clasificador los cuales son:

1. CARGAR BIBLIOTECAS IMPORTANTES:

Se llaman las bibliotecas importantes para la ejecución del modelo entre estas tenemos torch para pytorch...

2. PREPARACIÓN CONJUNTO DE DATOS:

La preparación del conjunto de datos es una etapa de importación en la creación y ejecución del algoritmo de red neuronal o también conocida como preprocesamiento de imágenes.

3. CONSTRUCCIÓN DEL MODELO

En esta parte se convierte la arquitectura de AlexNet presentada en la imagen ... en

código, para poder usarla más adelante en la clasificación. Además en este paso se definen los valores de el maxpooling, el padding y el número de convoluciones que tendra la red neuronal.

4. FORMACIÓN DEL MODELO

Durante el entrenamiento de la red AlexNet (entrenamiento durante ... epochs) se obtuvo una precisión de validación promedio del ..., como se muestra en la siguiente imagen:

5. PRUEBA DEL MODELO

En este paso se comprueba la eficiencia del modelo usando el dataset de validación, donde encontramos que la red AlexNet pudo predecir correctamente ... de ... imágenes de papas tanto defectuosas como en buen estado y reconociendo tambien el tamaño al que pertenecen ya sea grande, mediana o pequeña

MODELO PREENTRENADO VGG19

La arquitectura VGG fue planteada por Simonyan y Zisserman, la cual consiste en stacks lineales de bloques que se encuentran formados por una cantidad determinada de capas convolucionales, una función de activación no lineal y una capa Max Pooling, seguidos de tres capas fully-conected y finalmente una capa softmax (referencia pdf). Esta arquitectura cuenta con cinco bloques los cuales estan distribuidos de la siguiente manera:




Figura 5-5: Modelo VGG19

Como se puede observar en la imagen la arquitectura cuenta con dos capas convolucionales de 64 y 128 filtros respectivamente en sus dos primeros bloques, el bloque intermedio se compone de tres capas convolucionales de 256 filtros y los ultimos dos bloques estan compuestos por tres capas concolucionales de 512 filtros cada uno. El numero 19 representa la cantidad de capas entrenables que posee la arquitectura donde hay 16 capas convolucionales y 3 capas fully-conected.

Las capas convolucionales de esta arquitectura cuentan con un campo receptivo de 3x3, stride de 1x1 y padding de 1 pixel. Para la operaciones del Max Pooling se implementa un kernel de 2x2 y un stride de 2x2 y por ultimo cada capa oculta de la red cuenta con la funcion de activacion ReLu. La arquitectura VGG19 se resume en la siguiente tabla:

	Tipo	N filtros/parámetros
BLOQUE 1	Conv2D	64
	Conv2D	64
	Max Pool	N/A
BLOQUE 2	Conv2D	128
	Conv2D	128
	Max Pool	N/A
BLOQUE 3	Conv2D	256
	Conv2D	256
	Conv2D	256
	Conv2D	256
	Max Pool	N/A
BLOQUE 4	Conv2D	512
	Conv2D	512
	Conv2D	512
	Conv2D	512
	Max Pool	N/A
BLOQUE 5	Conv2D	512
	Conv2D	512
	Conv2D	512
	Conv2D	512
	Conv2D	512
	Max Pool	N/A
	Fully-Conn	4096
	Fully-Conn	4096
	Fully-Conn	1000
	Softmax	N

Figura 5-6: Composición Modelo VGG19

MODELO PREENTRENADO VGG11

MODELO PREENTRENADO RESNET18

COMPARACIÓN DE ARQUITECTURAS

5.2. Clasificación de tamaño

6 Prototipo

Bibliografía

- [1] “El aporte de la papa a la economía colombiana • periódico el campesino – la voz del campo colombiano.”
- [2] “Sector papero se prepara para aumentar el consumo de papa en colombia — finagro.”
- [3] J. Porras, M. De la Cruz, and A. Morán, “Classification system based on computer vision,” *Escuela Profesional de Ingeniería Electrónica-Universidad Ricardo Palma*: http://www.urp.edu.pe/pdf/ingenieria/electronica/CAP-1_Taller_de_Electronica_IV_b.pdf, 2014.
- [4] C. Nandi, “Machine vision based automatic fruit grading system using fuzzy algorithm,” 02 2014.
- [5] L. Pencue-Fierro and J. León Téllez, “Detección y clasificación de defectos en frutas mediante el procesamiento digital de imágenes,” *REVISTA COLOMBIANA DE FISICA*, vol. 35, 01 2003.
- [6] “Soybean plant foliar disease detection using image retrieval approaches,” *Multimedia Tools and Applications*, vol. 76, pp. 26647–26674, 12 2017.
- [7] K. R. Singh and S. Chaudhury, “Efficient technique for rice grain classification using back-propagation neural network and wavelet decomposition,” *IET Computer Vision*, vol. 10, pp. 780–787, 12 2016.
- [8] K. Przybyl, P. Boniecki, K. Koszela, L. Gierz, and M. Lukomski, “Computer vision and artificial neural network techniques for classification of damage in potatoes during the storage process,” *Czech Journal of Food Sciences*, vol. 37, pp. 135–140, 5 2019.
- [9] T. Liu, W. Wu, W. Chen, C. Sun, C. Chen, R. Wang, X. Zhu, and W. Guo, “A shadow-based method to calculate the percentage of filled rice grains,” *Biosystems Engineering*, vol. 150, pp. 79–88, 2016.
- [10] C.-L. Chung, K.-J. Huang, S.-Y. Chen, M.-H. Lai, Y.-C. Chen, and Y.-F. Kuo, “Detecting bakanae disease in rice seedlings by machine vision,” *Computers and Electronics in Agriculture*, vol. 121, pp. 404–411, 2016.

- [11] R. D. L. Pires, D. N. Gonçalves, J. P. M. Oruê, W. E. S. Kanashiro, J. F. Rodrigues, B. B. Machado, and W. N. Gonçalves, “Local descriptors for soybean disease recognition,” *Computers and Electronics in Agriculture*, vol. 125, pp. 48–55, 2016.
- [12] C. Sun, T. Liu, C. Ji, M. Jiang, T. Tian, D. Guo, L. Wang, Y. Chen, and X. Liang, “Evaluation and analysis the chalkiness of connected rice kernels based on image processing technology and support vector machine,” *Journal of Cereal Science*, vol. 60, no. 2, pp. 426–432, 2014.
- [13] T. Liu, W. Chen, W. Wu, C. Sun, W. Guo, and X. Zhu, “Detection of aphids in wheat fields using a computer vision technique,” *Biosystems Engineering*, vol. 141, pp. 82–93, 2016.
- [14] R. SOBOLU, M. CORDEA, I. POP, L. ANDRONIE, D. PUSTA, *et al.*, “Automatic sorting of potatoes according to their defects,” *Scientific Papers-Series B, Horticulture*, vol. 64, no. 1, pp. 462–468, 2020.
- [15] A. M. RODRIGUEZ, “Sistema automatizado de reconocimiento y manipulación de objetos usando visión por computadora y un brazo industrial,” 2014.
- [16] L. Han, M. S. Haleem, and M. Taylor, “A novel computer vision-based approach to automatic detection and severity assessment of crop diseases,” in *2015 Science and Information Conference (SAI)*, pp. 638–644, 2015.
- [17] M. Barnes, T. Duckett, G. Cielniak, G. Stroud, and G. Harper, “Visual detection of blemishes in potatoes using minimalist boosted classifiers,” *Journal of Food Engineering*, vol. 98, pp. 339–346, 2010.
- [18] V. Artificial, “Aplicación práctica de la visión artificial en el control de procesos industriales,” *Ministerio de Educación y Formación Profesional, Gobierno de España*, 2012.
- [19] “La camara fotografica cuerpo y controles basicos.”
- [20] T. Afridi, A. Alam, M. N. Khan, and J. Khan, “A multimodal memes classification: A survey and open research issues,” 09 2020.
- [21] D. A. Van Dyk and X.-L. Meng, “The art of data augmentation,” *Journal of Computational and Graphical Statistics*, vol. 10, no. 1, pp. 1–50, 2001.
- [22] “Pytorch documentation — pytorch 1.10.1 documentation.”
- [23] V. Mathivet, *Inteligencia artificial para desarrolladores: conceptos e implementación en C*. Ediciones ENI., 2018.